

Применение продвинутых DP техник в оптимизации

Мартынова Анна, Чернобай Андрей

17 апреля 2026 г.

Проблема

Риск запоминания и раскрытия нейросетями конфиденциальных данных из обучающей выборки.

Цель

Обеспечение защиты данных при умеренных затратах на качество модели и эффективность обучения.

Определение

Рандомизированный механизм $\mathcal{M} : \mathcal{D} \rightarrow \mathcal{R}$ с областью определения $\mathcal{D}$ и областью значений $\mathcal{R}$ удовлетворяет (ϵ, δ) -дифференциальной приватности, если для любых двух соседних входных данных $d, d' \in \mathcal{D}$ и для любого подмножества выходных данных $S \subseteq \mathcal{R}$ выполняется условие:

$$\Pr[\mathcal{M}(d) \in S] \leq e^\epsilon \Pr[\mathcal{M}(d') \in S] + \delta$$

Composition theorem

Теорема о базовой композиции

Пусть $\mathcal{M}_i : \mathcal{D} \rightarrow \mathcal{R}_i$ — алгоритм, удовлетворяющий $(\varepsilon_i, \delta_i)$ -дифференциальной приватности для каждого $i \in [k]$. Тогда, если механизм $\mathcal{M}_{[k]} : \mathcal{D} \rightarrow \prod_{i=1}^k \mathcal{R}_i$ определен как $\mathcal{M}_{[k]}(x) = (\mathcal{M}_1(x), \dots, \mathcal{M}_k(x))$, то $\mathcal{M}_{[k]}$ удовлетворяет $(\sum_{i=1}^k \varepsilon_i, \sum_{i=1}^k \delta_i)$ -дифференциальной приватности.

Privacy accountant

Определение

Для соседних баз данных $D, D' \in \mathcal{D}^n$, механизма $\mathcal{M}$ и результата $y \in \mathcal{R}$, определим privacy loss в точке y как:

$$c(\mathcal{M}, D, D', y) \triangleq \log \frac{\Pr[\mathcal{M}(D) = y]}{\Pr[\mathcal{M}(D') = y]}$$

Privacy accountant

Определение

Для соседних баз данных $D, D' \in \mathcal{D}^n$, механизма $\mathcal{M}$ и результата $y \in \mathcal{R}$, определим privacy loss в точке y как:

$$c(\mathcal{M}, D, D', y) \triangleq \log \frac{\Pr[\mathcal{M}(D) = y]}{\Pr[\mathcal{M}(D') = y]}$$

Определение

λ^{th} moment для механизма $\mathcal{M}$:

$$\alpha_{\mathcal{M}}(\lambda, D, D') \triangleq \log \mathbb{E}_{\xi \sim \mathcal{M}(D)}[\exp(\lambda c(\mathcal{M}, D, D', \xi))]$$

MGF (moment generating function) для механизма $\mathcal{M}$:

$$\alpha_{\mathcal{M}}(\lambda) \triangleq \max_{D, D'} \alpha_{\mathcal{M}}(\lambda, D, D')$$

Теорема

- ❶ [Composability] Пусть механизм $\mathcal{M}$ состоит из механизмов $\mathcal{M}_1, \dots, \mathcal{M}_k$. Тогда для любого λ :

$$\alpha_{\mathcal{M}}(\lambda) \leq \sum_{i=1}^k \alpha_{\mathcal{M}_i}(\lambda).$$

- ❷ [Tail bound] Для любого $\varepsilon > 0$ механизм $\mathcal{M}$ является (ε, δ) -дифференциально приватным для

$$\delta = \min_{\lambda} \exp(\alpha_{\mathcal{M}}(\lambda) - \lambda \varepsilon).$$

Algorithm 1 Differentially private SGD (Outline)

Input: Examples $\{x_1, \dots, x_N\}$, loss function $\mathcal{L}(\theta) = \frac{1}{N} \sum_i \mathcal{L}(\theta, x_i)$. Parameters: learning rate η_t , noise scale σ , group size L , gradient norm bound C .

Initialize θ_0 randomly

for $t \in [T]$ **do**

 Take a random sample L_t with sampling probability L/N

Compute gradient

 For each $i \in L_t$, compute $\mathbf{g}_t(x_i) \leftarrow \nabla_{\theta_t} \mathcal{L}(\theta_t, x_i)$

Clip gradient

$\bar{\mathbf{g}}_t(x_i) \leftarrow \mathbf{g}_t(x_i) / \max(1, \frac{\|\mathbf{g}_t(x_i)\|_2}{C})$

Add noise

$\tilde{\mathbf{g}}_t \leftarrow \frac{1}{L} (\sum_i \bar{\mathbf{g}}_t(x_i) + \mathcal{N}(0, \sigma^2 C^2 \mathbf{I}))$

Descent

$\theta_{t+1} \leftarrow \theta_t - \eta_t \tilde{\mathbf{g}}_t$

Output θ_T and compute the overall privacy cost (ϵ, δ) using a privacy accounting method.

Немного о компрессорах

Что это?

Компрессоры - это механизмы, предназначенные для уменьшения объёма данных, которыми обмениваются рабочие узлы и сервера.

Немного о компрессорах

Что это?

Компрессоры - это механизмы, предназначенные для уменьшения объёма данных, которыми обмениваются рабочие узлы и сервера.

Классы

- Пусть $\zeta \geq 1$. $C \in \mathbb{U}(\zeta)$, если $\mathbb{E}[C(x)] = x \quad \forall x$ и $\mathbb{E}[\|C(x)\|_2^2] \leq \zeta \|x\|_2^2 \quad \forall x \in \mathbb{R}^d$
- Пусть $\delta \geq 1$. $C \in \mathbb{B}^3(\delta)$, если $\mathbb{E}[\|C(x) - x\|_2^2] \leq (1 - \frac{1}{\delta}) \|x\|_2^2 \quad \forall x \in \mathbb{R}^d$

Немного о компрессорах

Что это?

Компрессоры - это механизмы, предназначенные для уменьшения объёма данных, которыми обмениваются рабочие узлы и сервера.

Классы

- Пусть $\zeta \geq 1$. $C \in \mathbb{U}(\zeta)$, если $\mathbb{E}[C(x)] = x \quad \forall x$ и $\mathbb{E}[\|C(x)\|_2^2] \leq \zeta \|x\|_2^2 \quad \forall x \in \mathbb{R}^d$
- Пусть $\delta \geq 1$. $C \in \mathbb{B}^3(\delta)$, если $\mathbb{E}[\|C(x) - x\|_2^2] \leq (1 - \frac{1}{\delta}) \|x\|_2^2 \quad \forall x \in \mathbb{R}^d$

Примеры

- Rand-k компрессор $\in \mathbb{U}(\frac{d}{k})$
- Top-k компрессор $\in \mathbb{B}^3(\frac{d}{k})$

Определение

$$\Delta_n f = \max_{D \sim D'} \|f(D) - f(D')\|_n$$

Sensitivity

Определение

$$\Delta_n f = \max_{D \sim D'} \|f(D) - f(D')\|_n$$

Используемый частный случай

$$s_f = \Delta_\infty f = \max_{D \sim D'} \|f(D) - f(D')\|_\infty$$

Лемма

Oneshot Laplace(Oneshot Gumbel) механизм является $(\epsilon, 0)$ -DP, если $\lambda \geq \frac{2ks_f}{\epsilon}$ ($\beta \geq \frac{2ks_f}{\epsilon}$)

Постановка задачи

Algorithm 2 The Oneshot C_{round} Gumbel Mechanism $\mathcal{M}^{os}$ for Privately Reporting Maximum k Elements

Require: database D , functions $f = (f_1, \dots, f_m)$ with sensitivity s_f , parameter k , noise scale β

Ensure: indices $i_1, \dots, i_k$ and approximations to $f_{i_1}(D), \dots, f_{i_k}(D)$

- 1: **for** $i = 1$ **to** m **do**
 - 2: set $y_i = C_{round}(f_i(D)) + g_i$ where g_i is sampled i.i.d. from $\text{Gumbel}(\beta)$
 - 3: **end for**
 - 4: sort $y_1, \dots, y_m$ from low to high, $y_{i_1} \leq y_{i_2} \leq \dots \leq y_{i_m}$
 - 5: **return** the set $\{i_{m-k+1}, \dots, i_m\}$ and $f_{i_j}(D) + g'_{i_j}$, where $m-k+1 \leq j \leq m$ and g'_{i_j} are fresh independent random noise sampled from $\text{Lap}(\lambda)$
-

Задача: реализовать приведённый выше алгоритм, сделать оценки его приватности и сходимости и сравнить его с уже известными DP-алгоритмами (DP-SGD, Oneshot Laplace Mechanism)

Механизм

Пусть $h = (h_1, \dots, h_d)$.

$$\mathcal{M}^{(1)}(h) = \arg \max_{i \in [d]} (h_i + X_i), \quad X_i \stackrel{\text{i.i.d.}}{\sim} \text{Gumbel}(\beta)$$

Теоретическая часть

Механизм

Пусть $h = (h_1, \dots, h_d)$.

$$\mathcal{M}^{(1)}(h) = \arg \max_{i \in [d]} (h_i + X_i), \quad X_i \stackrel{\text{i.i.d.}}{\sim} \text{Gumbel}(\beta)$$

Распределение $i \sim \mathcal{M}(h)$

$$P(\mathcal{M}(h) = i) = \frac{e^{\frac{h_i}{\beta}}}{\sum_{i=1}^d e^{\frac{h_i}{\beta}}}$$

Идея доказательства:

$$P(\mathcal{M}(h) = i) = P(h_i + X_i > h_j + X_j \ (\forall j \neq i)) = \int_{-\infty}^{+\infty} P(\mathcal{M}(h) = i \mid X_i = x) f_{X_i}(x) dx = \dots$$

MGF для $\mathcal{M}^{(1)}$

$$\alpha_{\mathcal{M}^{(1)}}(\lambda) \leq \frac{\lambda C}{\beta} + \lambda \mu + \frac{2C^2 \lambda^2}{\beta^2},$$

где $\Delta_i = h_i - h'_i$, $|\Delta_i| \leq C$, $\mu = \mathbb{E}_{i \sim \mathcal{M}(h)} \frac{\Delta_i}{\beta}$.

$$S(h) = \sum_{j=1}^d e^{\frac{h_j}{\beta}}$$

$$\alpha_{\mathcal{M}^{(1)}}(\lambda) = \lambda \log \frac{S(h')}{S(h)} + \log \mathbb{E}_{i \sim \mathcal{M}(h)} e^{\frac{\lambda \Delta_i}{\beta}}$$

Теоретическая часть

MGF для $\mathcal{M}^{(1)}$

$$\alpha_{\mathcal{M}^{(1)}}(\lambda) \leq \frac{\lambda C}{\beta} + \lambda \mu + \frac{2C^2 \lambda^2}{\beta^2},$$

где $\Delta_i = h_i - h'_i$, $|\Delta_i| \leq C$, $\mu = \mathbb{E}_{i \sim \mathcal{M}(h)} \frac{\Delta_i}{\beta}$.

$$S(h) = \sum_{i=1}^d e^{\frac{h_j}{\beta}}$$

$$\alpha_{\mathcal{M}^{(1)}}(\lambda) = \lambda \log \frac{S(h')}{S(h)} + \log \mathbb{E}_{i \sim \mathcal{M}(h)} e^{\frac{\lambda \Delta_i}{\beta}}$$

MGF для $\mathcal{M}^{(k)}$

$$\alpha_{\mathcal{M}^{(k)}}(\lambda) \leq \frac{2k\lambda C}{\beta} + \frac{2k\lambda^2 C^2}{\beta^2}$$

$$\mu \leq \frac{C}{\beta}$$

(ϵ, δ) -приватность

$$\delta = \exp\left[-\frac{\beta^2}{8kC^2}\left(\epsilon - \frac{2kC^2}{\beta}\right)\right]$$

Лемма

Пусть X и Y - i.i.d $\sim Gumbel(0, \beta)$. Пусть $Z = X - Y$. Тогда

$$f_Z(z) = \frac{\exp(-\frac{z}{\beta})}{\beta(1 + \exp(-\frac{z}{\beta}))^2}$$

, т.е. $Z \sim Logistic(0, \beta)$

Идея доказательства:

Просто считаем $f_Z(z) = \int_{-\infty}^{+\infty} f_X(x)f_Y(y)dx$

Теорема

Пусть $f_{(1)}(D) \leq f_{(2)}(D) \leq \dots \leq f_{(m)}(D)$ - порядковые статистики. Пусть $\Delta := \min_{1 \leq i \leq m-1} \{f_{(i+1)}(D) - f_{(i)}(D)\}$. Тогда с вероятностью как минимум

$$p(\Delta) = \max \left\{ 0, 1 - \frac{m-1}{1 + \exp\left(\frac{\Delta}{\beta}\right)} \right\}$$

Oneshot Top-k Gumbel механизм выдаёт множество из верных Top-k элементов.

Идея доказательства:

$$p(\Delta) \geq \mathbb{P}(f_{(1)}(D) + g_1 \leq f_{(2)}(D) + g_2, \dots, f_{(m-1)}(D) + g_{m-1} \leq f_{(m)}(D) + g_m)$$

где $g_1, g_2, \dots, g_m$ - i.i.d. $\sim \text{Gumbel}(0, \beta)$

Ещё немного о компрессорах

Определения

Пусть $\{a_k\}_{k \in \mathbb{Z}}$ - произвольная возр. посл-ть чисел, т.ч. $\inf a_k = 0$, $\sup a_k = \infty$.

- General unbiased rounding operator

$\left(\in \mathbb{U} \left(\frac{1}{4} \sup_{k \in \mathbb{Z}} \left(\frac{a_k}{a_{k+1}} + \frac{a_{k+1}}{a_k} + 2 \right) \right) \right) : a_k \leq |x_i| \leq a_{k+1}$ для i -ой координаты, то

$$C(x)_i = \begin{cases} \text{sign}(x_i) a_k & \text{with probability } \frac{a_{k+1} - |x_i|}{a_{k+1} - a_k} \\ \text{sign}(x_i) a_{k+1} & \text{with probability } \frac{|x_i| - a_k}{a_{k+1} - a_k} \end{cases}$$

- General biased rounding operator $\left(\in \mathbb{B}^3 \left(\sup_{k \in \mathbb{Z}} \frac{(a_k + a_{k+1})^2}{4a_k a_{k+1}} \right) \right):$

$$C(x)_i := \text{sign}(x_i) \arg \min_{t \in \{a_k\}} |t - |x_i||, \quad i \in [d].$$

Теоретическая часть

Для DP-Top-K

- $\mathbb{E}\|x - T_k(x)\|_2^2 = (1 - p(\Delta)^{\frac{k}{d}}) \|x\|_2^2$



Для Noise $\circ$ DP-Top-K

- $\mathbb{E}\|x - (T_k(x) + \xi_{Laplace})\|_2^2 = (1 - p(\Delta)^{\frac{k}{d}}) \|x\|_2^2 + 2d\lambda^2$
- $\mathbb{E}\|x - (T_k(x) + \xi_{Gumbel})\|_2^2 = (1 - p(\Delta)^{\frac{k}{2d}}) \|x\|_2^2 + \left(1 + \frac{2d}{p(\Delta)^k}\right) d\beta^2 \left(\frac{\pi^2}{6} + \gamma^2\right)$



Для LaplaceNoise $\circ$ DP-Top-K $\circ$ CRound

- $\mathbb{E}\|x - (T_k(C_{Unbiased}(x)) + \xi_{Laplace})\|_2^2 = (1 - p(\Delta)^{\frac{k}{d}}) \cdot \zeta \|x\|_2^2 + 2d\lambda^2$
- $\mathbb{E}\|x - (T_k(C_{Biased}(x)) + \xi_{Laplace})\|_2^2 = (1 - p(\Delta)^{\frac{k}{2d}}) \cdot \alpha \|x\|_2^2 + 2d\lambda^2,$
где $\alpha = \min\left(2, \sup_{k \in \mathbb{Z}} \frac{2a_{k+1}}{a_k + a_{k+1}}\right)$

Первые эксперименты



Первые эксперименты



А что дальше?

- Попытки получить более точные оценки приватности
- Оценка приватности механизма LaplaceNoise ◦ DP-Top-k ◦ GumbelNoise
- Доказательство характера сходимости нашего алгоритма
- Анализ первых экспериментальных результатов и поиск возможных ошибок
- Аккуратное сравнение алгоритмов при одинаковых гарантиях приватности