

Применение продвинутых DP техник в оптимизации

Мартынова Анна, Чернобай Андрей

Science Practicum Project. MIPT


Введение

Современные нейросети склонны запоминать и непреднамеренно раскрывать конфиденциальные данные из обучающих выборок. В связи с этим возникает необходимость внедрения строгих математических гарантий приватности. Дифференциальная приватность (DP) предоставляет надежную теоретическую базу для защиты данных.

Определение

Рандомизированный механизм $\mathcal{M} : \mathcal{D} \rightarrow \mathcal{R}$ удовлетворяет (ϵ, δ) -дифференциальной приватности, если для любых двух соседних входных данных $d, d' \in \mathcal{D}$ и для любого подмножества выходных данных $S \subseteq \mathcal{R}$ выполняется условие:


$$\Pr[\mathcal{M}(d) \in S] \leq e^\epsilon \Pr[\mathcal{M}(d') \in S] + \delta$$



В контексте дифференциальной приватности вычислительная сложность уступает место информационной (приватной) сложности. Она измеряется объемом раскрываемых данных: масштабом шума, числом открытых координат, размером переданных битов или числом запросов к БД.

Определение

Компрессоры - это механизмы, предназначенные для уменьшения объема данных, которыми обмениваются рабочие узлы и сервера.



Распространенные классы компрессоров:

- Rand- k :**

$$C(x) = \frac{d}{k} \sum_{i \in B, |B|=k, B \sim U[1, d]} x_i e_i$$

сохраняет k случайно выбранных координат вектора градиента, зануляя остальные.

- Тор- k :**

$$C(x) = \sum_{i=1}^k x_{(i)} e_{(i)}$$

оставляет k координат вектора с наибольшими абсолютными значениями.

Как сделать приватный Тор- k ?

Классический подход использует добавление шума Лапласа перед оператором Тор- k . Для обеспечения (ϵ, δ) -дифференциальной приватности параметр шума должен составлять:

$$\lambda \sim \sqrt{T \log \frac{Td}{\delta}}$$

где T — число итераций, а d — размерность пространства векторов.

Главная проблема заключается в том, что масштаб шума растет слишком быстро с увеличением числа итераций, а сама размерность d на практике может быть огромной. Это приводит к чрезмерному зашумлению градиентов и критической потере точности.

Решение: Механизм Гумбеля

Для обхода ограничений стандартного подхода предлагается добавлять Гумбелевский шум вместо Лапласовского.

Как показано в работе [1], метод в один проход математически эквивалентен пошаговому применению Экспоненциального механизма.

$$M_1(h) = \operatorname{argmax}_{i \in [d]} \{h_i + X_i : i \in [d]\},$$

$$X_i \stackrel{i.i.d.}{\sim} \operatorname{Gumbel}\left(\frac{1}{\epsilon}\right)$$

$M_k(h)$ - применение k раз M_1 .

Благодаря свойству ограниченности диапазона, алгоритм избавляется от жесткой зависимости от размерности d при композиции, что теоретически позволяет снизить стандартное отклонение шума в несколько раз.

Algorithm 1 The Oneshot Gumbel Mechanism $\mathcal{M}^{\text{os}}$ for Privately Reporting Maximum k Elements

Require: database D , functions $f = (f_1, \dots, f_m)$ with sensitivity s_f , parameter k , noise scale β

Ensure: indices $i_1, \dots, i_k$ and approximations to $f_{i_1}(D), \dots, f_{i_k}(D)$

1: **for** $i = 1$ to m **do**

2: set $y_i = f_i(D) + g_i$ where g_i is sampled i.i.d. from $\operatorname{Gumbel}(\beta)$

3: **end for**

4: sort $y_1, \dots, y_m$ from low to high, $y_{i_1} \leq y_{i_2} \leq \dots \leq y_{i_m}$

5: **return** the set $\{i_{m-k+1}, \dots, i_m\}$ and $f_{i_j}(D) + g'_{i_j}$, where $m-k+1 \leq j \leq m$ and g'_{i_j} are fresh independent random noise sampled from $\operatorname{Lap}(\lambda)$

В рамках нашей работы мы получили оценки накопления шума и сходимости такого алгоритма.

Теоретические оценки

Теорема

Для достижения (ϵ, δ) -дифференциальной приватности алгоритма за T итераций достаточно выбрать следующие параметры Гумбелевского (β) и Лапласовского (λ) шума:

$$\beta = \lambda = \frac{2C \sqrt{2T k \ln \frac{1}{\delta}}}{\epsilon},$$

где k — количество выбираемых координат оператором Тор- k , а C — константа ограничения чувствительности.

Итак, мы избавились от зависимости от размерности d , а также добились $\beta \sim \sqrt{T}$.

Также вот оценка сходимости рассматриваемого алгоритма:

Теорема




Пусть $\epsilon_k := \mathbb{E}[f(x^k)] - f(x^*)$ и $\epsilon_0 := f(x^0) - f(x^*)$. Тогда $\forall \eta \in [0, \frac{1}{L}]$ выполнено

$$\epsilon_k \leq \left(1 - \frac{\mu \eta}{\alpha}\right)^k \epsilon_0 + \frac{(1 + \alpha) \alpha}{\mu} d \lambda^2,$$

$$\text{где } \alpha = \frac{\left(p(\Delta) \frac{k}{d} - 2 + \frac{2}{\xi}\right) \pm \sqrt{\left(p(\Delta) \frac{k}{d} + \frac{2}{\xi}\right)^2 - \frac{8}{\xi}}}{2(1 - p(\Delta) \frac{k}{d})}.$$

Эксперименты

Эксперименты проводились на датасете MNIST. В качестве бейзлайн модели для быстрого обучения с разными механизмами шума нами была выбрана TinyCNN - облегчённая свёрточная сеть. В каждом эксперименте на всех механизмах обеспечивалась одна и та же (ϵ, δ) — приватность. Значения $\epsilon \in \{1, 3, 7\}, \delta \in \{10^{-5}\}$.



Эксперименты показали, что механизм Гумбеля не уступает классическому Лапласовскому подходу по точности и темпу сходимости. При этом за счет применения выведенных теоретических оценок параметров удалось существенно уменьшить дисперсию шума.

Литература

- David Durfee and Ryan Rogers. Practical differentially private top-k selection with pay-what-you-get composition. *arXiv preprint arXiv:1909.07876*, 2019.
- Martín Abadi, Andy Chu, Ian Goodfellow, H. Brendan McMahan, Ilya Mironov, Kunal Talwar, and Li Zhang. Deep learning with differential privacy. *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*, 2016.
- Gang Qiao, Weijie J. Su, and Li Zhang. One-shot differentially private top-k selection. *arXiv preprint arXiv:2002.12410*, 2020.
- Thomas Steinke. Composition of differential privacy & privacy amplification by subsampling. *arXiv preprint arXiv:2210.00597*, 2022.
- Cynthia Dwork and Aaron Roth. *The Algorithmic Foundations of Differential Privacy*. Now Publishers, Hanover, MA, USA, 2014.
- Aleksandr Beznosikov, Samuel Horváth, Peter Richtárik, and Mher Safaryan. On biased compression for distributed learning. *arXiv preprint arXiv:2105.08233*, 2021.